Adam Bista

Najpierw zimportujmy bazę Yelp na serwer lokalny. W tym celu po rozpakowaniu folderu yelp.zip wykonałem następujące komendy w cmd:

```
mongoimport --db yelp --collection business --file "C:\\<pełna ścieżka do folderu>\\yelp \\business.json"

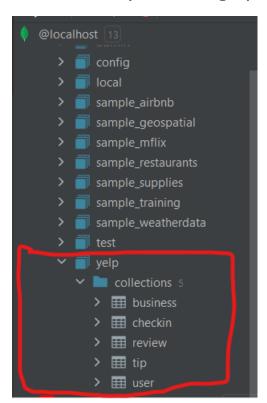
mongoimport --db yelp --collection checkin --file "C:\\<pełna ścieżka do folderu >\\yelp \\checkin.json"

mongoimport --db yelp --collection review --file "C:\\<pełna ścieżka do folderu >\\yelp \\review.json"

mongoimport --db yelp --collection tip --file "C:\\<pełna ścieżka do folderu >\\yelp \\tip.json"

mongoimport --db yelp --collection user --file "C:\\<pełna ścieżka do folderu >\\yelp \\user.json"
```

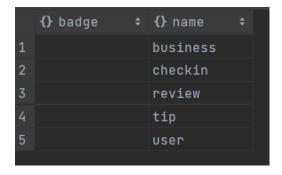
Widok bazy w datagripie:



Wpisujemy polecenia do konsoli:

```
use yelp; show collections;
```

Wynik:



ZADANIA

- 1. Operacje wyszukiwania danych
 - a. Zapytanie:

```
use yelp;
db.business.find({
    "categories": { $in: ["Restaurants"] },
    "hours.Monday": { $exists: true, $ne: "" },
    "stars": { $gte: 4 }
}, {_id: 0,
    name: 1,
    address: 1,
    categories: 1,
    hours: 1,
    stars: 1}
    ).sort({
    name:1
    })
```

wyniki:

```
O categories

1 ["Food", "Gesserts", "Coffee & Tea", "Indian", "Rest ("Monday": {"close": "22:00", "open": "18:00"), "Tue | 10-to-10 In Delhi |
2 ["Vistnamese", "Asian Fusion", "French", "Restaurant ("Monday": ("close": "22:00", "open": "11:00"), "Frei 188 Restaurant |
3 ["Baser", "Asian Fusion", "Mightlife", "Lounges", "Ma ("Monday": ("close": "05:00"), "open": "18:00"), "Tue | 24 Carrots Juice Bar & Cafe |
4 ["Food", "Live/Raw Food", "Juice Bars & Smoothies", ("Monday": ("close": "14:00", "open": "08:00"), "Tue | 24 Carrots Juice Bar & Cafe |
5 ["Sreakfast & Brunch", "Gulten-Free", "Wegetarian", ("Monday": ("close": "14:00", "open": "08:00"), "Tue | 24 Carrots Juice Bar & Cafe |
5 ["Sakeries", "Food", "Breakfast & Brunch", "Coffee & ("Monday": ("close": "14:00", "open": "18:00"), "Tue | 24 Carrots Juice Bar & Cafe |
6 ["Asian Fusion", "Restaurants"] | ("Monday": ("close": "14:00", "open": "08:00"), "Tue | 25 Carrots Juice Bar & Cafe |
7 ["Cafes", "Food", "Breakfast & Brunch", "Gulter | ("Monday": ("close": "14:00", "open": "07:00"), "Tue | 4620 Bakery & Cafe |
9 ["Cafes", "American (Indictional)", "Oiners", "Restaurants"] | ("Monday": ("close": "14:00", "open": "09:00"), "Tue | 4621 Bakery & Cafe |
9 ["Cafes", "Restaurants"] | ("Monday": ("close": "14:00", "open": "11:00"), "Tue | 4621 Bayers |
12 ["Bars", "Restaurants"] | ("Monday": ("close": "20:00", "open": "11:00"), "Tue | 4521 Bayers |
13 ["Food", "Ethnic Food", "That", "Specialty Food", "R ("Monday": ("close": "20:00", "open": "11:00"), "Tue | 5 Reha That Bistro |
14 ["Food", "Ethnic Food", "That", "Specialty Food", "R ("Monday": ("close": "20:00", "open": "11:00"), "Tue | 5 Reha That Bistro |
14 ["Food", "Ethnic Food", "That", "Specialty Food", "R ("Monday": ("close": "20:00", "open": "11:00"), "Tue | 5 Reha That Bistro |
15 ["Caterers", "Event Planning & Services", "Barbeque" | (Monday": ("close": "20:00", "open": "11:00"), "Tue | 5 S Canoes Tikl Den |
16 ["Barsk', "Rightlife", "British", "Restaurants"] | ("Monday": ("close": "10:00", "open": "11:00")
```

Pasujących danych jest o wiele więcej, wyświetliłem tylko 20 pasujących.

b. Zapytanie:

Wynik:



Jak widać najwięcej hoteli podanych kategorii znajduje się w Las Vegas, niemal 2 razy więcej niż w Phoenix

c. Zapytanie:

```
use yelp;
db.tip.aggregate([
```

Uwaga! W powyższym przykładzie tuż po połączeniu tip oraz business zrobiłem ograniczenie do pokazania 100 pierwszych wyników. Bez tego ograniczenia całe zapytanie trwałoby bardzo długo.

Wynik:

d. Zapytanie:

Wynik:

W powyższym zapytaniu użyłem **\$cond**, w którym zdefiniowałem warunek oznaczania recenzji. Jeśli liczba głosów danej kategorii przy wybranej recenzji jest większa lub równa 1 to powinien zwrócić 1, gdyż dana kategoria posiada jakiekolwiek głosy. W przeciwnym wypadku 0. Jest to potrzebne do zliczania kategorii wziętych pod uwagę w **\$group**.

e. Zapytanie:

Wynik:

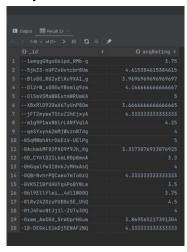
```
| Company | Comp
```

Wyniki są posortowane względem pola name alfabetycznie. Nazwy A znajdują się pod innymi imionami, gdyż przed nimi znajdują się dodatkowe znaki, które powodują wcześniejsze wyświetlanie.

f. Zapytanie:

i. Przypadek:

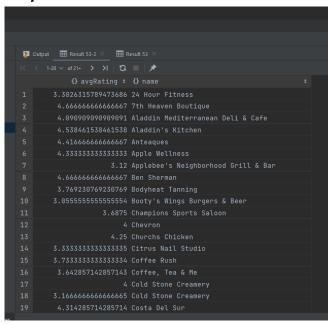
Wyniki:



ii. Przypadek:

Jak widać użyłem ograniczenia do wyświetlenia 100 danych od razu po połączeniu review z business. Zrobiłem to dlatego, gdyż liczba danych jest ogromna i czas oczekiwania na wyniki był bardzo długi.

Wyniki:



2. Tworzenie bazy

a. Podejście znormalizowane

i. Wady i zalety oraz struktura kolekcji:

W tym podejściu będziemy mieli cztery osobne kolekcje: 'Professors', 'Subjects', 'Students' i 'Grades'. Każdy dokument będzie zawierał id referencyjne do innych dokumentów, co pozwoli na tworzenie złożonych relacji.

1. Zalety:

- a. Separacja danych: każda kategoria danych jest przechowywana oddzielnie – zwiększa czytelność bazy
- b. Redukcja redundancji zmniejszone ryzyko niezgodności danych

2. Wady:

- a. Konieczność łączenia danych zapytania mogą być bardziej skomplikowane
- b. Zmniejszona wydajność większa ilość zapytań do bazy

Struktura bazy danych:

Professors:

```
{
    "_id": ObjectId(),
    "name": "Jan Kowalski",
    "email": "jan.kowalski@example.com",
    "subjects": [ObjectId(), ObjectId(), ...] // Referencje do
dokumentów z kolekcji Subjects
}
```

Subjects:

```
{
    "_id": ObjectId(),
    "name": "Fizyka",
    "professor": ObjectId() // Referencja do dokumentu z
kolekcji Professors
}
```

Students:

```
{
    "_id": ObjectId(),
    "name": "Anna Nowak",
    "email": "anna.nowak@example.com",
    "subjects": [ObjectId(), ObjectId(), ...] // Referencje do
dokumentów z kolekcji Subjects
}
```

Grades:

```
{
    "_id": ObjectId(),
    "student": ObjectId(), // Referencja do dokumentu z
kolekcji Students
    "subject": ObjectId(), // Referencja do dokumentu z
kolekcji Subjects
    "grade": 5,
    "date": ISODate("2023-05-20")
}
```

ii. Wprowadzanie przykładowych danych:

```
//Tworzenie bazy danych
use university;
```

```
//Tworzenie kolekcji

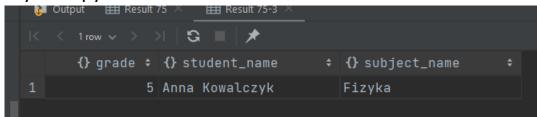
db.createCollection('Professors')
db.createCollection('Subjects')
db.createCollection('Students')
db.createCollection('Grades')
```

iii. Przykłady

Załóżmy, że chcemy wyświetlić imię i nazwisko studenta, jego przedmioty i oceny z tych przedmiotów. Nasze całe zapytanie będzie wyglądać tak:

```
} },
{$unwind:"$subjectInfo"},
{ $lookup: {
    from: "Students",
    localField: "student",
    foreignField: "_id",
    as: "studentInfo"
} },
{$unwind:"$studentInfo"},
{
    $project: {
        _id:0,
        student_name: "$studentInfo.name",
        subject_name:"$subjectInfo.name",
        grade:"$grade"
}
}
```

Wynik zapytania:



Aby uzyskać wyświetlenie podanych trzech informacji musieliśmy wykonać złożone zapytanie - połączyliśmy ze sobą aż 3 różne kolekcje. Dodatkowo wydajność jest zmniejszona, gdyż trzeba było wykonać skomplikowane zapytanie (podpunkty a i b do wad)

Jeśli chcielibyśmy zaktualizować adres e-mail profesora, to wystarczy zrobić to tylko w jednym miejscu (separacja danych):

Wynik operacji:

Jak widać, wystarczyło w jednym miejscu dokonać zmiany, aby rezultat był widoczny w każdym miejscu.

Jeśli wykładowca wystawi ocenę z jakiegoś przedmiotu, to nie musimy przechowywać tych samych informacji w dokumentach studenta, wykładowcy i przedmiotu. Informacje te są przechowywane tylko w dokumencie z ocenami (zmniejszenie redundancji)

```
db.Grades.insertOne({
    "student": db.Students.findOne({name: "Anna Kowalczyk"})._id,
    "subject": db.Subjects.findOne({name: "Matematyka"})._id,
    "grade": 4,
    "date": new Date()
});
```

Wykonajmy wcześniejsze zapytanie:

Wynik:

Wszystkie pliki odnośnie tego podejścia znajdują się w katalogu "podejście znormalizowane", baza danych znajduje się w folderze dump

Na koniec usuwamy bazę:

use university;
db.dropDatabase()

c. Podejście odnormalizowane (embedded documents)

i. Wady i zalety oraz tworzenie kolekcji:

W podejściu odnormalizowanym (embedded documents) dokumenty są zagnieżdżone wewnątrz innych dokumentów. Kolekcje mogą wyglądać tak:

- Professors zawierająca listę przedmiotów prowadzonych przez danego profesora
- Students zawierająca listę przedmiotów, które student obecnie uczęszcza, wraz z ocenami otrzymanymi od wykładowców

1. Zalety

- Mniejsza ilość zapytań do bazy zapytania są prostsze i szybsze, ponieważ większość informacji można uzyskać z pojedynczego dokumentu
- Wyższa wydajność zmniejsza się ilość operacji, ponieważ dane są często przechowywane w taki sposób, że do najczęściej używanych informacji można uzyskać dostęp za pomocą pojedynczego zapytania

2. Wady

- Zwiększona redundancja danych te same informacje mogą być przechowywane w wielu miejscach
- Może być trudno zarządzać aktualizacjami jeśli te same dane są przechowywane w wielu miejscach, trzeba je zaktualizować we wszystkich miejscach, co może być trudne i prowadzić do niezgodności

Struktura bazy danych:

Professors:

Students:

ii. Wprowadzanie przykładowych danych

```
//tworzymy bazę
use university;
```

```
//dodajemy kolekcje
db.createCollection("Professors")
db.createCollection("Students")
```

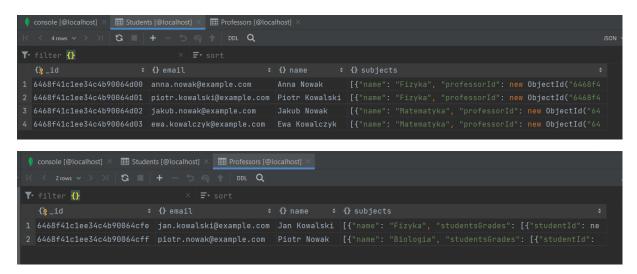
```
//Teraz, gdy mamy ID dla każdego profesora i studenta,
//możemy dodać informacje o przedmiotach i ocenach. Pobierzmy najpierw ID
dla profesorów i studentów:

let janKowalskiId = db.Professors.findOne({ name: "Jan Kowalski" })._id;
let piotrNowakId = db.Professors.findOne({ name: "Piotr Nowak" })._id;
let annaNowakId = db.Students.findOne({ name: "Anna Nowak" })._id;
let piotrKowalskiId = db.Students.findOne({ name: "Piotr Kowalski" })._id;
let jakubNowakId = db.Students.findOne({ name: "Jakub Nowak" })._id;
let ewaKowalczykId = db.Students.findOne({ name: "Ewa Kowalczyk" })._id;
```

```
);
db.Students.updateOne(
```

```
db.Students.updateOne(
);
db.Students.updateOne(
```

Wyniki w tabelach:

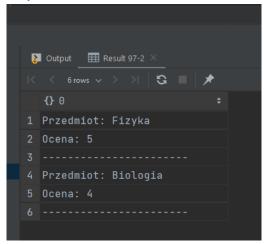


iii. Przykłady

Jeżeli chcielibyśmy sprawdzić oceny studenta, wszystko jest zawarte w jednym dokumencie, a nasze zapytanie jest bardzo proste: (Zalety a i b)

```
var student = db.Students.findOne({ name: "Anna Nowak" });
  for (var i = 0; i < student.subjects.length; i++) {
    var subject = student.subjects[i];
    print("Przedmiot: " + subject.name);
    print("Ocena: " + subject.grade);
    print("------");
}</pre>
```

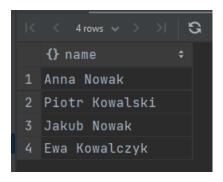
Wynik:



(**Zmniejszona ilość operacji**) Chcielibyśmy znaleźć wszystkich studentów, którzy są uczeni przez konkretnego profesora. Dzięki temu, że mamy ID profesora zapisane bezpośrednio przy przedmiotach, zapytanie jest bardzo proste i szybkie:

```
use university;
let professorId = db.Professors.findOne({ "name": "Jan Kowalski" })._id;
db.Students.find({ "subjects.professorId": professorId }, {name:1, _id:0});
```

Wynik:



(Wady a i b) Jeśli na przykład zmieni się ocena, musimy zaktualizować ją zarówno w dokumencie profesora, jak i studenta:

W pewnych sytuacjach może to doprowadzić wielu błędów, jeśli się nie zna dokładnej struktury tabel.

Teraz wykonując poprzednie zapytanie:

```
var student = db.Students.findOne({ name: "Anna Nowak" });
  for (var i = 0; i < student.subjects.length; i++) {
    var subject = student.subjects[i];
    print("Przedmiot: " + subject.name);
    print("Ocena: " + subject.grade);
    print("------");
}</pre>
```

W wyniku otrzymamy:

Wszystkie pliki odnośnie tego podejścia znajdują się w katalogu "podejście odnormalizowane", baza danych znajduje się w folderze dump

Na koniec usuwamy bazę:

```
use university;
db.dropDatabase()
```